

Sistema inteligente adaptativo para detección de fraude

Evaluación temporal del dataset IEEE-CIS Fraud Detection

Edgar Moisés Chambilla Mamani
José Joaquín Osnayo Matos
Luis Anthony Romero Padilla
André Martin Benjamin Torres Ramos
José Francisco Wong Orrillo

Proyecto 1: Planificación y Toma de Decisiones en IA

Septiembre de 2026

Profesores: Dra. Auras Soariane Vargas · Mg. Robert Buleje Del-Carpio

Resumen

Este trabajo desarrolla un sistema de clasificación para detectar fraude financiero en datos cuyo comportamiento cambia con el tiempo. Parte de la línea base del informe técnico anterior, que integra las tablas de transacciones e identidad, normaliza variables temporales y entrena XGBoost. La extensión añade agregaciones causales por cliente implícito, ventanas expansivas y deslizantes, monitoreo de drift con PSI y decisiones basadas en costos. La evaluación usa 590 540 transacciones y bloques futuros de 30 días. La ventana expansiva alcanza un AUC promedio de 0,9163; la ventana de 30 días llega a 0,9039. En esta corrida, conservar más historia funciona mejor que descartar datos de forma agresiva.

1 Problema, objetivos y restricciones

El problema es clasificar cada transacción como legítima o fraudulenta antes de autorizarla. El dataset IEEE-CIS contiene 590 540 transacciones, 20 663 fraudes (3,50 %) y una tabla de identidad disponible solo para una parte de los casos. La variable **TransactionDT** ordena aproximadamente seis meses de actividad, por lo que una validación aleatoria produciría fuga de información.

El objetivo es maximizar la detección futura manteniendo controlados los falsos positivos. Las restricciones son los datos tabulares ofuscados, el desbalance 1:27, la ausencia de un identificador real de cliente, la memoria limitada de una RTX 2060 de 6 GB y el retraso en la disponibilidad de las etiquetas. El protocolo no usa submisiones a Kaggle.

Métricas. Se reportan AUC y PR-AUC para ranking, precision, recall, F1 y balanced accuracy para clasificación. Para decisiones se usa un umbral 0,20, costo 1 para falso positivo y costo 10 para falso negativo. También se reportan tiempo de entrenamiento y PSI.

2 Diseño del sistema

El flujo recibe las tablas transaccional y de identidad, valida el orden temporal, calcula variables causales, produce un score y lo convierte en una acción: aprobar, enviar a revisión o bloquear. Las transacciones y decisiones se registran para medir desempeño y drift. La tabla transaccional describe el evento de pago; la tabla de identidad aporta información sobre el dispositivo y la red.

3 Preparación temporal y features

Los valores faltantes se conservan como señal; las variables categóricas se codifican con un ordinal encoder capaz de manejar categorías nuevas. Se derivan día relativo, hora, día de semana, mes calendario y versiones normalizadas de D_4 , D_5 , D_{10} , D_{11} y D_{15} .

Sistema inteligente adaptativo para detección de fraude

El feedback de desempeño y drift decide cuándo actualizar el modelo




Figura 1: Arquitectura del sistema. El monitoreo alimenta la selección de ventana y el reentrenamiento.

El cliente implícito se aproxima como:

$$UID = card1_addr1_ [TransactionDT/86400 - D1].$$

El UID solo se utiliza como llave. Para cada fila se calculan frecuencia y medias históricas de monto, variables temporales y conteos. Durante el entrenamiento se usa la suma acumulada anterior a la fila; durante la evaluación se usa únicamente el histórico anterior al bloque. Así se elimina la fuga transductiva del benchmark original.

4 Modelado y protocolo experimental

Se comparan regresión logística, Random Forest y XGBoost. La comparación auxiliar usa el mismo corte temporal de la muestra de desarrollo. El experimento principal usa XGBoost, que fue el modelo con mejor resultado en el informe base.

La evaluación adaptativa reserva los primeros 60 días para entrenamiento y evalúa cuatro bloques futuros de 30 días. Se comparan:

- histórico expansivo: conserva todos los días anteriores;
- ventana deslizante de 30, 60 o 90 días: olvida observaciones antiguas;
- PSI sobre monto, columnas D y conteos C ; PSI máximo mayor que 0,20 activa una alarma;
- reentrenamiento por bloque, con posibilidad de cambiar la ventana cuando aumente el costo.

5 Resultados

La tabla resume la corrida completa sobre las 590 540 transacciones de entrenamiento, con XGBoost de 180 árboles y umbral 0,20.

Tabla 1: Promedios de los cuatro bloques futuros.

Ventana	AUC	PR-AUC	F1	Recall	PSI máx.
Expansiva	0,9163	0,5807	0,5575	0,5131	0,0403
30 días	0,9039	0,5630	0,5481	0,4786	0,0133
60 días	0,9139	0,5759	0,5585	0,5045	0,0238
90 días	0,9156	0,5829	0,5635	0,5151	0,0295

La ventana expansiva alcanza el mejor AUC promedio. La ventana de 30 días presenta el peor resultado, lo que indica que descartar historia puede eliminar patrones útiles. El rendimiento también cambia entre bloques: el AUC expansivo baja de 0,9175 en el primero a 0,9071 en el segundo, mientras el




Figura 2: Evolución temporal de AUC, F1 y PSI. El segundo bloque muestra una degradación del modelo expansivo, aunque el PSI no supera el umbral alto.

costo de decisión sube de 18 059 a 21 009. El sistema vigila el PSI y las métricas de desempeño cuando llegan las etiquetas retrasadas.

Tabla 2: Comparación auxiliar de modelos en el mismo corte temporal de desarrollo.

Modelo	AUC	F1	Recall
Regresión logística	0,8022	0,0940	0,9686
Random Forest	0,9000	0,1588	0,9186
XGBoost	0,9242	0,6163	0,5831

El costo de la causalidad, medido. El script `src/eval_05_integrated.py` cuantificó la brecha transductiva sobre el sistema integrado del notebook 05. La variante protocolo reproduce sus AUC (0,9340/0,9456 en holdout, 0,9347/0,9509 en OOF) y añade métricas de decisión en umbrales 0,50, 0,19 y calibrado. La variante causal calcula las agregaciones del UID solo con el pasado: entrenamiento en [0 %, 60 %), calibración en [60 %, 75 %) y evaluación en el futuro; el AUC del holdout baja de 0,9456 a 0,9175. El umbral calibrado $\tau^* = 0,108$ sostiene F1 0,60 en el bloque futuro.

Tabla 3: Sistema integrado 05 + magic UID, holdout causal 75/25 (`results/threshold_metrics_05_causal.csv`).

Umbral	Recall	Precisión	F1
0,50	0,3218	0,9308	0,4782
0,19	0,4200	0,8903	0,5707
$\tau^* = 0,108$ (calibrado)	0,4602	0,8651	0,6008

6 Despliegue, riesgos y adaptación

En un despliegue por lotes diario o mensual, las nuevas transacciones pasan por validación, cálculo de features históricas y predicción. El modelo se actualiza al cerrar cada bloque o cuando se detecta drift. Los casos cercanos al umbral se envían a revisión humana; el sistema no debe bloquear de forma irreversible sin auditoría. La incertidumbre se aproxima mediante la distancia al umbral y puede mejorarse con calibración posterior.

Los principales riesgos son la fuga temporal en las agregaciones, los cambios en la cobertura de identidad, las nuevas campañas de fraude, el costo desigual de los errores y la degradación silenciosa. Para reducirlos se necesitan registros, versionado del modelo, rollback, revisión de alertas y evaluación por período.

7 Conclusiones

El informe base mostró que la ingeniería de entidades aporta más que cambiar de algoritmo. La extensión adaptativa lleva esa evidencia a un flujo operativo: calcula features causales, evalúa bloques futuros y compara estrategias de olvido. En esta ejecución, la ventana expansiva supera a la de 30 días. La selección de ventana debe apoyarse en métricas de desempeño y costo, y el umbral conviene recalibrarlo por bloque sin usar el futuro: en el sistema integrado, la variante causal del holdout costó 0,028 de AUC y sostuvo F1 0,60 con $\tau^* = 0,108$. El código reproducible se encuentra en `src/adaptive_fraud.py` y `src/eval_05_integrated.py`; los resultados, en `results/adaptive_results.csv`, `results/threshold_metrics_05_integrated.csv` y `results/threshold_metrics_05_causal.csv`.