

Sistema inteligente adaptativo para detección de fraude

IEEE-CIS Fraud Detection · datos no estacionarios

DATOS

orden temporal

590 540

transacciones

MODELO

score de fraude

+0,0116 AUC

ganancia con magic UID

ADAPTACIÓN

PSI + ventanas

4 ventanas

temporales de evaluación

Edgar Chambilla · Septiembre 2026

Qué problema resolvemos

El modelo debe reconocer fraude en transacciones posteriores al período de entrenamiento

590 540

transacciones de entrenamiento

3,50 %

fraudes · desbalance 1:27

Consecuencia del desbalance

Un modelo que siempre prediga “no fraude” tendría accuracy alta y no detectaría ningún caso fraudulento.

Escenario del proyecto

Cada fila integra varias fuentes sobre una misma operación: la transacción, la tarjeta, la dirección y la identidad del dispositivo, además del monto y el tiempo. El train cubre varios meses y el test ocurre después.

Decisión que queremos tomar

El sistema asigna un score de fraude. Ese score se convierte en una acción: aprobar, revisar o bloquear la operación.

Pregunta de adaptación

¿Cuánto histórico debe conservar el modelo para mantener su rendimiento en el siguiente bloque temporal?

Qué limita el sistema

Restricciones de datos, operación, recursos y decisiones que el sistema no puede tomar

Datos

Solo 3,5 % de las filas es fraude, así que accuracy y desbalance no conviven bien. El test ocurre después del train: ningún modelo ve el futuro que evalúa. El cliente real no existe en los datos; `card1+addr1` lo aproxima.

Operación y recursos


El score corre por lotes diario o mensual, sin respuesta en tiempo real. La GPU de 6 GB y la ejecución local acotan el tamaño de cada experimento.

Decisiones vedadas

Ningún bloqueo irreversible sin auditoría. Los casos cercanos al umbral van a revisión humana.


Cómo son los datos

Análisis exploratorio en Python sobre las 590 540 transacciones del train



Monto de la transacción

Las distribuciones de fraude y de operaciones legítimas se solapan: el monto por sí solo no separa las clases.



Hora del día

La tasa de fraude cambia a lo largo del día. El tiempo aporta señal y obliga a validar hacia el futuro.

Cómo leer las métricas

Cada métrica responde una pregunta distinta; el desbalance impide resumir todo con accuracy

Término	Qué significa	Cómo se lee aquí
Accuracy	Proporción total de predicciones correctas.	0,9787 parece alto porque 96,5 % de las filas no son fraude.
Recall	De todos los fraudes reales, cuántos detecta el modelo.	0,5981 equivale a detectar cerca de 60 fraudes por cada 100.
Precisión	De todas las alertas, cuántas corresponden a fraude.	0,7429 equivale a 74 fraudes por cada 100 alertas.
F1	Resume el equilibrio entre recall y precisión.	Aumentó de 0,6062 a 0,6627 al ajustar el umbral.
Balanced acc.	Promedia el recall de fraude y el de operaciones legítimas.	Pasó de 0,7269 a 0,7953 al bajar el umbral a 0,19.
AUC	Evalúa si el modelo ordena los fraudes por encima de las operaciones legítimas.	0,5 sería azar; el mejor OOF del proyecto llegó a 0,9509.
Umbral	Score mínimo a partir del cual se activa una alerta.	Bajar de 0,50 a 0,19 recuperó más fraude y redujo la precisión.

Métricas de decisión y sociales

Las métricas técnicas se completan con lo que cada error le cuesta a la operación y a las personas

Decisión

Con la ventana de 90 días el costo medio por bloque es de 17 336. El umbral 0,19 se eligió por ese balance entre fraude recuperado y alertas falsas.

Cobertura y riesgo

La alerta alcanza entre 2,7 % y 3,5 % de las transacciones según el bloque. En el primero quedaron 1 689 fraudes sin detectar y 1 169 alertas falsas.

Equidad: protocolo propuesto

El dataset no registra atributos demográficos. La primera medición posible compara recall y precisión entre transacciones de UID sin historial y UID con historial, porque un cliente nuevo concentra los errores. Si existieran atributos de grupo, se reportaría por bloque la diferencia de recall y de falsos positivos entre grupos.

Términos de validación y herramientas utilizadas

Las decisiones metodológicas reproducen el orden temporal del problema

Validación temporal

Holdout	Entrena con el primer 75 % y evalúa en el 25 % posterior.
OOF	Cada fila se predice con un modelo que no la usó para entrenar.
GroupKFold mensual	Mantiene cada mes completo dentro de un fold.
Ventana	Cantidad de pasado que el modelo conserva al reentrenar.
Drift	Cambio de la distribución de datos a lo largo del tiempo.
PSI	Indicador numérico de drift; se usa 0,20 como umbral de alerta.
Leakage	Uso accidental de información futura durante el entrenamiento.

Herramientas y motivo de uso

pandas / NumPy	Carga, unión y transformación reproducible de los CSV.
XGBoost	Modelo tabular capaz de aprender relaciones no lineales y usar GPU.
LightGBM	Alternativa eficiente para comparar algoritmo e ingeniería de datos.
GPU	Reduce tiempo de entrenamiento; no garantiza un AUC mayor.
Magic UID	Reconstruye contexto de cliente que no existe como columna original.
PSI	Permite monitorear cambios de distribución después del despliegue.

La tasa de fraude cambia con el tiempo

La línea representa el porcentaje diario; la referencia punteada marca la media global de 3,5 %



Qué se observa


La proporción diaria se mueve por encima y por debajo de la media. Algunos períodos concentran picos cercanos al 7 %.

Por qué importa

Una partición aleatoria mezcla estos períodos. La evaluación por bloques conserva la dirección real del tiempo.

El contexto de cliente mejora el AUC

Las barras comparan modelos sobre validaciones temporales; una barra más larga indica mejor ordenamiento



Lectura de la gráfica

En el mismo corte, regresión logística alcanzó 0,8022 y random forest 0,9000 de AUC; XGBoost llegó a 0,9242. La GPU acertó tiempos sin mover el AUC; el salto definitivo viene del historial por UID.

0,9479


mejor AUC local

+0,0104

ganancia magic UID

Ablación propia: medir el aporte del magic UID

Notebook 05 · XGBoost d12 GPU · semilla 42 · mismo modelo, hardware y split



Qué cambia

El modelo base usa 198 features. Las 47 adicionales resumen el historial del pseudo-cliente; el resto del experimento permanece igual.

Resultado


Holdout: 0,9340 → 0,9456.
OOF: 0,9347 → 0,9509.

Interpretación

La mejora aparece en ambos protocolos, por lo que no depende de un solo corte temporal.

Cómo se construye el magic UID

El pseudo-cliente sirve para calcular historia; el identificador crudo se elimina antes de entrenar




El UID crudo se elimina antes del entrenamiento

Lectura del flujo

card1+addr1 aproxima tarjeta y dirección; floor(day-D1) aproxima la fecha de alta. Las agregaciones permiten comparar una transacción con el comportamiento previo de su grupo.

Del score a una decisión que puede auditarse

El modelo produce un score; el umbral y el monitoreo determinan la acción



Durante la predicción

XGBoost combina las features y entrega un score. El umbral traduce ese valor en aprobar, revisar o bloquear.

Después de la predicción


Recall, F1, AUC, PSI y costo se calculan por bloque. Una degradación sostenida activa la revisión de ventana y el reentrenamiento.

Cerca del umbral

La distancia al umbral indica qué tan firme es cada decisión. Los scores de la zona gris van a revisión humana; una calibración posterior puede afinar esa frontera.

El umbral 0,19 recupera más fraude

Sistema integrado 05 · OOF GroupKFold mensual $\times 3$ · 590 540 transacciones



Umbral 0,50

Detecta 45,6 de cada 100 fraudes.
De cada 100 alertas, 90,6 corresponden a fraude.

Umbral 0,19


Detecta 59,8 de cada 100 fraudes.
La precisión baja a 74,3 alertas correctas por cada 100.

Balance obtenido

F1 sube de 0,6062 a 0,6627.
Accuracy se queda en 0,979 y no refleja el ajuste.

Sin fuga temporal, el AUC cae y la decisión se sostiene

Mismo sistema 05: estadísticas con todo el train vs. calculadas solo con el pasado



Holdout causal: métricas por umbral

Umbral	Recall	Precisión	F1
0,50	0,3218	0,9308	0,4782
0,19	0,4200	0,8903	0,5707
0,108 calibrado	0,4602	0,8651	0,6008


Qué significa la caída

Las agregaciones del protocolo original incluían el período evaluado; calculadas solo con el pasado, el AUC baja 0,028.

El umbral calibrado por F1 en el bloque 60–75 % sin ver el futuro sostiene F1 0,60 en el bloque posterior.

Cada bloque futuro usa únicamente información pasada

Ejemplo del bloque 4: entrenamiento hasta el día 150 y evaluación en los 30 días siguientes




Cómo leer la línea de tiempo

Las barras muestran cuánto pasado conserva cada estrategia. La zona rosada queda fuera del entrenamiento. La ventana expansiva acumula todo el historial; las ventanas móviles descartan datos antiguos.

Las ventanas responden a objetivos distintos

Corrida canónica: results/adaptive_results.csv · 4 bloques · XGBoost 180 árboles



Promedios por ventana

Ventana	AUC	Recall	F1
Expansiva	0,9163	0,5131	0,5575
90 días	0,9156	0,5151	0,5635
60 días	0,9139	0,5045	0,5585
30 días	0,9039	0,4786	0,5481

Lectura y monitoreo

Expansiva obtiene el mejor AUC. La ventana de 90 días logra el mejor recall, F1 y costo medio (17 336).

El PSI medio máximo queda bajo 0,05, lejos del umbral 0,20. La caída del bloque 2 exige vigilar también desempeño y costo.

Autonomía del sistema

Qué decide la máquina sola, qué decide con supervisión y qué queda en manos humanas

Automático

Score por transacción, alerta según el umbral calibrado y cálculo de métricas y PSI por bloque. Ninguna de estas tareas requiere intervención.

Semiautomático

El reentrenamiento y el cambio de ventana se activan cuando el desempeño o el PSI se degradan. La política nueva se revisa antes de entrar en producción.

Humano

El bloqueo de operaciones, la auditoría de alertas y la recalibración del umbral requieren una persona.

Nivel elegido

Semiautomático: el sistema mantiene el modelo por su cuenta, y toda decisión que afecta a un cliente conserva revisión humana.

Riesgos de un sistema dinámico

Reflexión final sobre confianza, estabilidad y decisión automatizada

Qué puede fallar

Fuga temporal en las agregaciones, cobertura de identidad que cambia con el tiempo, campañas de fraude nuevas, costo desigual de los errores y degradación silenciosa del modelo.

Mitigación

Registro de cada predicción, versionado del modelo con rollback, revisión de alertas y evaluación por período.

Lo que los resultados muestran

El PSI medio quedó bajo 0,03 en los cuatro bloques y aun así el AUC cayó en el segundo: vigilar variables no reemplaza vigilar decisiones.

Límites de la política

La ventana corta descarta drift viejo y también señal estable: con 30 días el AUC medio bajó a 0,9039. El umbral se calibró con datos pasados; una campaña nueva puede desalinearlo.

Recomendación operativa

La política se elige según el costo de cada error y la métrica que se desea proteger

Magic UID causal + ventana por objetivo + umbral calibrado por costo

Representación

Usar agregaciones por pseudo-cliente. Aportaron +0,0116 AUC en holdout y +0,0162 en OOF.

Memoria temporal

Usar expansiva si se prioriza AUC y 90 días si se priorizan recall, F1 y costo.

Decisión

Iniciar con umbral calibrado por F1 (0,18 en OOF; 0,108 en causal) y recalibrarlo cuando cambien los costos o el fraude.

Siguiente evaluación

Probar la política con costos reales de falsos positivos y falsos negativos en un bloque posterior no utilizado durante el desarrollo.

Apéndice · reproducibilidad

Semillas, hardware, fuentes de datos y artefactos ejecutables

Semillas

Notebook / script	Semilla
01 baseline CPU	0 (default)
02 XGBoost GPU	2019
03 LightGBM	47 / 11
04 magic UID	sin semilla explícita
05 integrado	42
adaptativo	42

Hardware

16 núcleos CPU · NVIDIA RTX 2060 6 GB
· ejecución local sin submissions.

Fuentes canónicas

results/RANKING_FINAL.csv
results/bench_05_integrated.csv
results/threshold_metrics_05_integrated.csv
results/threshold_metrics_05_causal.csv
results/adaptive_results.csv

Código y entregables

codigos/ejecutados/01--05
src/adaptive_fraud.py
src/eval_05_integrated.py
presentacion/generar_figuras.py
informe_latex/main_entrega.pdf