

# Sistema inteligente adaptativo para detección de fraude

IEEE-CIS Fraud Detection · datos no estacionarios · Septiembre 2026

**590 540**

transacciones

**+0,0116 AUC**

ganancia con magic UID

**4 ventanas**

temporales de evaluación

## EQUIPO

Chambilla Mamani · Osnayo Matos · Romero Padilla · Torres Ramos  
· Wong Orrillo

## PROFESORES

Dra. Auras Soariane Vargas  
Mg. Robert Buleje Del-Carpio

# Equipo

Quiénes desarrollaron el sistema y quiénes lo guiaron

## Integrantes

Edgar Moisés Chambilla Mamani  
José Joaquín Osnayo Matos  
Luis Anthony Romero Padilla  
André Martin Benjamin Torres Ramos  
José Francisco Wong Orrillo

## Profesores

Dra. Auras Soariane Vargas  
Mg. Robert Buleje Del-Carpio

Septiembre 2026

# Qué problema resolvemos

El modelo debe reconocer fraude en transacciones posteriores al período de entrenamiento

**590 540**

transacciones de entrenamiento

**3,50 %**

fraudes · desbalance 1:27

## Consecuencia del desbalance

Un modelo que siempre prediga “no fraude” tendría accuracy alta y no detectaría ningún caso fraudulento.

## Escenario del proyecto

Cada fila integra varias fuentes sobre una misma operación: la transacción, la tarjeta, la dirección y la identidad del dispositivo, además del monto y el tiempo. El train cubre varios meses y el test ocurre después.

## Decisión que queremos tomar

El sistema asigna un score de fraude. Ese score se convierte en una acción: aprobar, revisar o bloquear la operación.

## Pregunta de adaptación

¿Cuánto histórico debe conservar el modelo para mantener su rendimiento en el siguiente bloque temporal?

# Qué limita el sistema

Restricciones de datos, operación, recursos y decisiones que el sistema no puede tomar

## Datos

Solo 3,5 % de las filas es fraude, así que accuracy y desbalance no conviven bien. El test ocurre después del train: ningún modelo ve el futuro que evalúa. El cliente real no existe en los datos; `card1+addr1` lo aproxima.

## Operación y recursos


El score corre por lotes diario o mensual, sin respuesta en tiempo real. La GPU de 6 GB y la ejecución local acotan el tamaño de cada experimento.

## Decisiones vedadas

Ningún bloqueo irreversible sin auditoría. Los casos cercanos al umbral van a revisión humana.


# Cómo son los datos

## Análisis exploratorio en Python sobre las 590 540 transacciones del train



### Monto de la transacción

Las distribuciones de fraude y de operaciones legítimas se solapan: el monto por sí solo no separa las clases.



### Hora del día

La tasa de fraude cambia a lo largo del día. El tiempo aporta señal y obliga a validar hacia el futuro.

# Cómo leer las métricas

Cada métrica responde una pregunta distinta; el desbalance impide resumir todo con accuracy

| Término       | Qué significa                                                                   | Cómo se lee aquí                                                |
|---------------|---------------------------------------------------------------------------------|-----------------------------------------------------------------|
| Accuracy      | Proporción total de predicciones correctas.                                     | 0,9787 parece alto porque 96,5 % de las filas no son fraude.    |
| Recall        | De todos los fraudes reales, cuántos detecta el modelo.                         | 0,5981 equivale a detectar cerca de 60 fraudes por cada 100.    |
| Precisión     | De todas las alertas, cuántas corresponden a fraude.                            | 0,7429 equivale a 74 fraudes por cada 100 alertas.              |
| F1            | Resume el equilibrio entre recall y precisión.                                  | Aumentó de 0,6062 a 0,6627 al ajustar el umbral.                |
| Balanced acc. | Promedia el recall de fraude y el de operaciones legítimas.                     | Pasó de 0,7269 a 0,7953 al bajar el umbral a 0,19.              |
| AUC           | Evalúa si el modelo ordena los fraudes por encima de las operaciones legítimas. | 0,5 sería azar; el mejor OOF del proyecto llegó a 0,9509.       |
| Umbral        | Score mínimo a partir del cual se activa una alerta.                            | Bajar de 0,50 a 0,19 recuperó más fraude y redujo la precisión. |

# Métricas de decisión y sociales

Las métricas técnicas se completan con lo que cada error le cuesta a la operación y a las personas

## Decisión

Con la ventana de 90 días el costo medio por bloque es de 17 336. El umbral 0,19 se eligió por ese balance entre fraude recuperado y alertas falsas.

## Cobertura y riesgo

La alerta alcanza entre 2,7 % y 3,5 % de las transacciones según el bloque. En el primero quedaron 1 689 fraudes sin detectar y 1 169 alertas falsas.

## Equidad: protocolo propuesto

El dataset no registra atributos demográficos. La primera medición posible compara recall y precisión entre transacciones de UID sin historial y UID con historial, porque un cliente nuevo concentra los errores. Si existieran atributos de grupo, se reportaría por bloque la diferencia de recall y de falsos positivos entre grupos.

# Términos de validación y herramientas utilizadas

Las decisiones metodológicas reproducen el orden temporal del problema

## Validación temporal

|                           |                                                                 |
|---------------------------|-----------------------------------------------------------------|
| <b>Holdout</b>            | Entrena con el primer 75 % y evalúa en el 25 % posterior.       |
| <b>OOF</b>                | Cada fila se predice con un modelo que no la usó para entrenar. |
| <b>GroupKFold mensual</b> | Mantiene cada mes completo dentro de un fold.                   |
| <b>Ventana</b>            | Cantidad de pasado que el modelo conserva al reentrenar.        |
| <b>Drift</b>              | Cambio de la distribución de datos a lo largo del tiempo.       |
| <b>PSI</b>                | Indicador numérico de drift; se usa 0,20 como umbral de alerta. |
| <b>Leakage</b>            | Uso accidental de información futura durante el entrenamiento.  |

## Herramientas y motivo de uso

|                       |                                                                      |
|-----------------------|----------------------------------------------------------------------|
| <b>pandas / NumPy</b> | Carga, unión y transformación reproducible de los CSV.               |
| <b>XGBoost</b>        | Modelo tabular capaz de aprender relaciones no lineales y usar GPU.  |
| <b>LightGBM</b>       | Alternativa eficiente para comparar algoritmo e ingeniería de datos. |
| <b>GPU</b>            | Reduce tiempo de entrenamiento; no garantiza un AUC mayor.           |
| <b>Magic UID</b>      | Reconstruye contexto de cliente que no existe como columna original. |
| <b>PSI</b>            | Permite monitorear cambios de distribución después del despliegue.   |

# La tasa de fraude cambia con el tiempo

La línea representa el porcentaje diario; la referencia punteada marca la media global de 3,5%



## Qué se observa


La proporción diaria se mueve por encima y por debajo de la media. Algunos períodos concentran picos cercanos al 7%.

## Por qué importa

Una partición aleatoria mezcla estos períodos. La evaluación por bloques conserva la dirección real del tiempo.

# El contexto de cliente mejora el AUC

Las barras comparan modelos sobre validaciones temporales; una barra más larga indica mejor ordenamiento



## Lectura de la gráfica

En el mismo corte, regresión logística alcanzó 0,8022 y random forest 0,9000 de AUC; XGBoost llegó a 0,9242. La GPU acertó tiempos sin mover el AUC; el salto definitivo viene del historial por UID.

**0,9479**


mejor AUC local

**+0,0104**

ganancia magic UID

# Ablación propia: medir el aporte del magic UID

Notebook 05 · XGBoost d12 GPU · semilla 42 · mismo modelo, hardware y split



## Qué cambia

El modelo base usa 198 features. Las 47 adicionales resumen el historial del pseudo-cliente; el resto del experimento permanece igual.

## Resultado


Holdout: 0,9340 → 0,9456.  
OOF: 0,9347 → 0,9509.

## Interpretación

La mejora aparece en ambos protocolos, por lo que no depende de un solo corte temporal.

# Cómo se construye el magic UID

El pseudo-cliente sirve para calcular historia; el identificador crudo se elimina antes de entrenar




El UID crudo se elimina antes del entrenamiento

## Lectura del flujo

card1+addr1 aproxima tarjeta y dirección; floor(day-D1) aproxima la fecha de alta. Las agregaciones permiten comparar una transacción con el comportamiento previo de su grupo.

# Del score a una decisión que puede auditarse

El modelo produce un score; el umbral y el monitoreo determinan la acción



## Durante la predicción

XGBoost combina las features y entrega un score. El umbral traduce ese valor en aprobar, revisar o bloquear.

## Después de la predicción


Recall, F1, AUC, PSI y costo se calculan por bloque. Una degradación sostenida activa la revisión de ventana y el reentrenamiento.

## Cerca del umbral

La distancia al umbral indica qué tan firme es cada decisión. Los scores de la zona gris van a revisión humana; una calibración posterior puede afinar esa frontera.

# El umbral 0,19 recupera más fraude

Sistema integrado 05 · OOF GroupKFold mensual  $\times 3$  · 590 540 transacciones



## Umbral 0,50

Detecta 45,6 de cada 100 fraudes.  
De cada 100 alertas, 90,6 corresponden a fraude.

## Umbral 0,19


Detecta 59,8 de cada 100 fraudes.  
La precisión baja a 74,3 alertas correctas por cada 100.

## Balance obtenido

F1 sube de 0,6062 a 0,6627.  
Accuracy se queda en 0,979 y no refleja el ajuste.

# Sin fuga temporal, el AUC cae y la decisión se sostiene

Mismo sistema 05: estadísticas con todo el train vs. calculadas solo con el pasado



## Holdout causal: métricas por umbral

| Umbral                 | Recall        | Precisión | F1            |
|------------------------|---------------|-----------|---------------|
| 0,50                   | 0,3218        | 0,9308    | 0,4782        |
| 0,19                   | 0,4200        | 0,8903    | 0,5707        |
| <b>0,108 calibrado</b> | <b>0,4602</b> | 0,8651    | <b>0,6008</b> |


## Qué significa la caída

Las agregaciones del protocolo original incluían el período evaluado; calculadas solo con el pasado, el AUC baja 0,028.

El umbral calibrado por F1 en el bloque 60–75 % sin ver el futuro sostiene F1 0,60 en el bloque posterior.

# Cada bloque futuro usa únicamente información pasada

Ejemplo del bloque 4: entrenamiento hasta el día 150 y evaluación en los 30 días siguientes




## Cómo leer la línea de tiempo

Las barras muestran cuánto pasado conserva cada estrategia. La zona rosada queda fuera del entrenamiento. La ventana expansiva acumula todo el historial; las ventanas móviles descartan datos antiguos.

# Las ventanas responden a objetivos distintos

Corrida canónica: results/adaptive\_results.csv · 4 bloques · XGBoost 180 árboles



## Promedios por ventana

| Ventana   | AUC           | Recall        | F1            |
|-----------|---------------|---------------|---------------|
| Expansiva | <b>0,9163</b> | 0,5131        | 0,5575        |
| 90 días   | 0,9156        | <b>0,5151</b> | <b>0,5635</b> |
| 60 días   | 0,9139        | 0,5045        | 0,5585        |
| 30 días   | 0,9039        | 0,4786        | 0,5481        |

## Lectura y monitoreo

Expansiva obtiene el mejor AUC. La ventana de 90 días logra el mejor recall, F1 y costo medio (17 336).

El PSI medio máximo queda bajo 0,05, lejos del umbral 0,20. La caída del bloque 2 exige vigilar también desempeño y costo.

# Autonomía del sistema

Qué decide la máquina sola, qué decide con supervisión y qué queda en manos humanas

## Automático

Score por transacción, alerta según el umbral calibrado y cálculo de métricas y PSI por bloque. Ninguna de estas tareas requiere intervención.

## Semiautomático

El reentrenamiento y el cambio de ventana se activan cuando el desempeño o el PSI se degradan. La política nueva se revisa antes de entrar en producción.

## Humano

El bloqueo de operaciones, la auditoría de alertas y la recalibración del umbral requieren una persona.

## Nivel elegido

Semiautomático: el sistema mantiene el modelo por su cuenta, y toda decisión que afecta a un cliente conserva revisión humana.

# Riesgos de un sistema dinámico

## Reflexión final sobre confianza, estabilidad y decisión automatizada

### Qué puede fallar

Fuga temporal en las agregaciones, cobertura de identidad que cambia con el tiempo, campañas de fraude nuevas, costo desigual de los errores y degradación silenciosa del modelo.

### Mitigación

Registro de cada predicción, versionado del modelo con rollback, revisión de alertas y evaluación por período.

### Lo que los resultados muestran

El PSI medio quedó bajo 0,03 en los cuatro bloques y aun así el AUC cayó en el segundo: vigilar variables no reemplaza vigilar decisiones.

### Límites de la política

La ventana corta descarta drift viejo y también señal estable: con 30 días el AUC medio bajó a 0,9039. El umbral se calibró con datos pasados; una campaña nueva puede desalinearlo.

## Recomendación operativa

La política se elige según el costo de cada error y la métrica que se desea proteger

### Magic UID causal + ventana por objetivo + umbral calibrado por costo

#### Representación

Usar agregaciones por pseudo-cliente. Aportaron +0,0116 AUC en holdout y +0,0162 en OOF.

#### Memoria temporal

Usar expansiva si se prioriza AUC y 90 días si se priorizan recall, F1 y costo.

#### Decisión

Iniciar con umbral calibrado por F1 (0,18 en OOF; 0,108 en causal) y recalibrarlo cuando cambien los costos o el fraude.

#### Siguiente evaluación

Probar la política con costos reales de falsos positivos y falsos negativos en un bloque posterior no utilizado durante el desarrollo.

# Apéndice · reproducibilidad

Semillas, hardware, fuentes de datos y artefactos ejecutables

## Semillas

| Notebook / script | Semilla               |
|-------------------|-----------------------|
| 01 baseline CPU   | 0 (default)           |
| 02 XGBoost GPU    | 2019                  |
| 03 LightGBM       | 47 / 11               |
| 04 magic UID      | sin semilla explícita |
| 05 integrado      | 42                    |
| adaptativo        | 42                    |

## Hardware

16 núcleos CPU · NVIDIA RTX 2060 6 GB  
· ejecución local sin submissions.

## Fuentes canónicas

results/RANKING\_FINAL.csv  
results/bench\_05\_integrated.csv  
results/threshold\_metrics\_05\_integrated.csv  
results/threshold\_metrics\_05\_causal.csv  
results/adaptive\_results.csv

## Código y entregables

codigos/ejecutados/01--05  
src/adaptive\_fraud.py  
src/eval\_05\_integrated.py  
presentacion/generar\_figuras.py  
informe\_latex/main\_entrega.pdf