

PROYECTO 1

Sistema inteligente adaptativo para detección de fraude

IEEE-CIS Fraud Detection · datos no estacionarios

Línea base reproducida, ventanas temporales y monitoreo de drift

DATOS

orden temporal

MODELO

score de fraude

ADAPTACIÓN

PSI + ventanas

medir → decidir → ajustar

Edgar Chambilla · Septiembre 2026

La distribución del fraude cambia con el tiempo


El modelo se entrena con pasado y se evalúa en bloques futuros

590 540

transacciones de entrenamiento

3,50 %

fraudes · desbalance 1:27



La tasa de fraude varía a lo largo del tiempo de la competencia.

Riesgo de validación

La validación aleatoria puede inflar el AUC: ordenamos por tiempo y reservamos bloques futuros.

La mayor mejora viene de cómo representamos los datos


El mismo XGBoost mejora cuando incorpora contexto del cliente implícito

+0,0104

AUC con magic UID

Ranking local

Método	AUC	Tiempo
XGB d12 + magic UID	0,9479	192 s GPU
XGB d12 sin UID	0,9375	163 s GPU
LightGBM + RFE	0,9200	462 s CPU
XGBoost GPU	0,9227	25 s GPU
XGBoost CPU base	0,9191	112 s CPU





Ablación ejecutada en local: con y sin magic UID

Notebooks 04 y 05 · XGBoost d12 GPU · semilla 42 · validación temporal honesta

Sistema integrado (05): holdout 75/25 y OOF mensual $\times 3$

Modelo	Holdout	OOF
sin UID	0,9340	0,9347
+ magic UID	0,9456	0,9509
ganancia	+0,0116	+0,0162

La ganancia proviene de la **representación de datos**: mismo algoritmo, mismo hardware y misma semilla. La validación debe ser temporal; un KFold aleatorio infla el resultado.



El score se convierte en una decisión auditable

Las métricas indican cuándo actualizar el modelo


1. Datos: transacción + identidad
2. Validación: orden temporal
3. Features: UID causal + D
4. Modelo: XGBoost
5. Score: incertidumbre
6. Decisión: aprobar / revisar / bloquear
7. Monitoreo: AUC · PSI · costo
8. Adaptación: ventana + reentrenamiento

Métricas de decisión (mejor modelo, OOF)

Umbral	Accuracy	Recall	Precisión
0,50	0,9801	0,4751	0,9132
0,19 (F1*)	0,9801	0,6082	0,7737

Sistema inteligente adaptativo para detección de fraude

El feedback de desempeño y drift decide cuándo actualizar el modelo



Cada bloque futuro usa solo la información disponible


El entrenamiento y las agregaciones respetan el instante de cada transacción

60 días inicial → bloques de
30 días

ventanas evaluadas: 30 / 60 / 90 /
expansiva

Criterio de actualización

PSI alto o caída de desempeño →
revisar ventana y reentrenar. Sin
alarma, conservar el modelo.



Dominan conteos, deltas D y tarjetas: por eso funcionan las
agregaciones por cliente.

Reducir la historia no garantiza mejor rendimiento

Corrida completa: 590 540 transacciones, bloques futuros de 30 días, XGBoost de 180 árboles

0,9163


AUC medio · expansiva

0,9039

AUC medio · 30 días

0,5831

recall medio (expansiva)



El segundo bloque degrada desempeño aunque el PSI no supere el umbral alto: se monitorean ambas señales.

Olvidar datos *no* siempre mejora:
la ventana debe validarse
temporalmente.

Conclusiones

La línea base orienta la adaptación

Features causales

El UID aporta contexto de entidad sin usar información futura: +0,01 AUC de pura ingeniería de representación.

Ventanas comparables

La ventana expansiva fue la mejor en esta corrida (AUC 0,9163 vs 0,9039 con 30 días).

Monitoreo operativo

AUC, PSI y costo de decisión deciden cuándo reentrenar; el accuracy alto engaña con desbalance 1:27: el recall dirige el umbral.

Reproducibilidad

Notebook / script	Semilla
01 baseline CPU	0 (default)
02 XGBoost GPU	2019
03 LightGBM	47 / 11
04 magic UID	determinístico
05 integrado	42
adaptativo	42

Código: `src/adaptive_fraud.py`

Notebooks: `codigos/ejecutados/01--05`

Informe corto:

`informe_latex/main_entrega.pdf`